

Project Brief Datathon

Microsoft Elevate Training Center

Informasi Peserta

No	Nama	Email Decoding
1	Jeremy Sean Sitranata	jremysie@gmail.com
2	Stevan Pohan	stevanpoh7@gmail.com
3	Takeshi Henderson Herman	takeshihenderson02@gmail.com

- **Topik : Ekonomi Digital & Inklusi Keuangan**
- **Ringkasan Eksekutif**

Latar Belakang

Indonesia mengalokasikan anggaran perlindungan sosial sebesar Rp496,8 triliun dalam APBN 2024. Meski komitmen fiskal ini masif, per September 2024 masih terdapat 24,06 juta penduduk miskin atau sekitar 8,57% dari total populasi. Kondisi ketimpangan yang tercermin dari rasio Gini sebesar 0,381 menunjukkan bahwa distribusi bantuan sosial masih menghadapi tantangan besar dalam mencapai keadilan sosial yang merata.

Problem Statement

Sistem bantuan sosial saat ini mengandalkan Proxy Means Testing (PMT) yang bersifat statis dan berbasis aset fisik. Kelemahan fatalnya adalah akurasi yang menurun seiring waktu (data tidak real-time). Pemerintah mengakui exclusion error (warga miskin yang tidak terdata) pernah mencapai 46%. Meskipun ada transisi ke DTSEN (Data Tunggal Sosial Ekonomi Nasional), tantangan sinkronisasi dan inkonsistensi desil kesejahteraan masih menjadi hambatan besar bagi keadilan sosial.

Research Questions

1. Dapatkah model Machine Learning (ML) yang dilatih pada data simulasi yang merepresentasikan distribusi sosio-ekonomi riil memprediksi desil kesejahteraan dengan akurasi lebih tinggi dibanding PMT konvensional?
2. Pola anomali fitur apa yang paling berkontribusi terhadap terjadinya mis-targeting dalam sistem distribusi bantuan sosial saat ini?

3. Fitur apa yang paling prediktif untuk mendeteksi penerima yang seharusnya sudah keluar dari sistem (graduation)?

Mengapa Proyek Ini?

Urgensi proyek ini didasari oleh temuan riset University of Groningen (Maret 2025) yang membuktikan bahwa pendekatan Spatial Machine Learning mampu mereduksi exclusion error secara signifikan, dari 28% menjadi 20% dibandingkan model standar. Mengingat ekosistem perlindungan sosial Indonesia bernilai hampir Rp500 triliun per tahun, optimasi akurasi melalui sistem berbasis Machine Learning yang canggih dan berkelanjutan memiliki potensi besar untuk mentransformasi efektivitas bantuan, sekaligus menyelamatkan jutaan keluarga dari jerat kemiskinan.

RightAid hadir sebagai solusi strategis melalui platform ML-PMT Refresher. Sistem ini memanfaatkan data sintesis berlabel untuk menghitung ulang skor kelayakan rumah tangga secara dinamis serta mensimulasikan berbagai skenario ketidaktepatan sasaran (mis-targeting). Dengan RightAid, pemerintah dapat memperoleh rekomendasi kebijakan yang presisi dan dapat segera ditindaklanjuti, tanpa harus bergantung pada survei lapangan skala nasional yang memakan waktu lama dan biaya besar.

● Deskripsi Project

RightAid adalah platform analitik berbasis web yang dikembangkan untuk membantu analis kebijakan mengevaluasi potensi ketidaktepatan sasaran (*mis-targeting*) pada program perlindungan sosial di Indonesia. Platform ini mengintegrasikan dua kapabilitas utama, yaitu *Synthetic Data Engine* dan *ML-PMT Dashboard*, ke dalam satu antarmuka yang dapat dioperasikan tanpa memerlukan keahlian pemrograman khusus.

Melalui *Synthetic Data Engine*, sistem secara otomatis menghasilkan dataset rumah tangga sintetis yang secara statistik realistis berdasarkan data agregat BPS dari Susenas dan Regsosek. Pendekatan data sintetis ini digunakan sebagai solusi atas kerahasiaan data individu penerima bantuan sosial, sebuah metode yang juga diakui secara ilmiah dan diterapkan oleh lembaga multilateral seperti World Bank dan UNDP. Selanjutnya, *ML-PMT Dashboard* menyajikan hasil klasifikasi serta perbandingan antara prediksi *Machine Learning* dan PMT konvensional, lengkap dengan panel SHAP (*SHapley Additive exPlanations*) untuk menjelaskan alasan di balik setiap prediksi secara transparan bagi pengambil keputusan.

Secara teknis, RightAid bekerja dengan melakukan *reverse-engineering* terhadap variabel kelayakan dari regulasi resmi, seperti Permensos No. 5 Tahun 2019 dan indikator Regsosek, guna membangun skema data yang identik dengan standar pemerintah. Sistem kemudian menggunakan distribusi statistik Susenas per provinsi untuk menciptakan populasi sintetis yang mencerminkan realitas geografis Indonesia. Pada tahap akhir, model XGBoost dilatih untuk memprediksi desil kesejahteraan dan mendeteksi anomali, yang hasilnya dapat dijadikan bahan advokasi kebijakan untuk memperbaiki akurasi penyaluran bantuan.

Platform ini ditujukan bagi analis kebijakan di Kementerian Sosial, Bappenas, hingga Dinas Sosial di tingkat provinsi. Dengan menggunakan RightAid, mereka dapat memvalidasi atau memperbarui model PMT secara berkala tanpa harus bergantung sepenuhnya pada survei lapangan skala nasional yang membutuhkan biaya miliaran rupiah dan waktu penyelesaian hingga bertahun-tahun.

● Fitur Utama dan Teknologi yang Digunakan

A. Pipeline Data Sintetis & Ekstraksi Fitur

Agar model tidak hanya belajar dari *noise*, pembuatan data sintetis dalam RightAid menggunakan pendekatan *multivariate data generation* (seperti *Synthetic Data Vault* / SDV atau model Copula) untuk menjaga korelasi logis antar variabel.

Pada dasarnya, arsitektur RightAid dirancang untuk mengakomodasi **25 variabel kelayakan standar** yang diadaptasi penuh dari kuesioner Regsosek dan DTKS.

A. Demografi & Komposisi Rumah Tangga

- ❖ `jml_anggota_keluarga`: Integer (1-12)
- ❖ `usia_kepala_keluarga`: Integer (18-90)
- ❖ `gender_kepala_keluarga`: Kategorikal (Laki-laki / Perempuan)
- ❖ `dependency_ratio`: Float (Rasio anggota keluarga non-produktif vs produktif)

B. Kondisi Fisik Bangunan (Fokus Utama PMT Lama)

- ❖ `status_kepemilikan_rumah`: Kategorikal (Milik Sendiri, Kontrak/Sewa, Bebas Sewa, Dinas)
- ❖ `luas_lantai_per_kapita`: Float (m² per orang)
- ❖ `jenis_lantai`: Kategorikal (Tanah, Bambu, Kayu Kualitas Rendah, Semen, Keramik, Marmer)
- ❖ `jenis_dinding`: Kategorikal (Bambu/Rumbia, Kayu, Tembok Tanpa Plester, Tembok Diplester)
- ❖ `jenis_atap`: Kategorikal (Ijuk/Rumbia, Asbes, Seng, Genteng)

C. Utilitas & Sanitasi

- ❖ `sumber_air_minum`: Kategorikal (Sumur Tak Terlindung, Mata Air, Sumur Bor, PAM/Ledeng, Air Kemasan)
- ❖ `fasilitas_bab`: Kategorikal (Bebas/Alam, Jamban Bersama, Jamban Sendiri - Leher Angsa)
- ❖ `daya_listrik_terpasang`: Kategorikal (Tidak Ada, 450 VA, 900 VA, 1300 VA, >2200 VA) 13.
`bahan_bakar_memasak`: Kategorikal (Kayu Bakar, Minyak Tanah, Gas 3kg, Gas >3kg / Listrik)

D. Ekonomi & Aset

- ❖ pendidikan_kepala_keluarga: Kategorikal (Tidak Sekolah, SD, SMP, SMA, Perguruan Tinggi)
- ❖ status_pekerjaan_kk: Kategorikal (Tidak Bekerja, Pekerja Informal, Pekerja Formal/Karyawan, Wirausaha)
- ❖ sektor_pekerjaan_kk: Kategorikal (Pertanian, Jasa, Manufaktur, Konstruksi, dll.)
- ❖ pengeluaran_per_kapita: Float (Estimasi pengeluaran bulanan - fitur paling dinamis)
- ❖ kepemilikan_motor: Integer (0, 1, >1)
- ❖ kepemilikan_mobil: Integer (0, 1, >1)
- ❖ aset_lahan_pertanian: Kategorikal (Tidak Ada, <0.5 Ha, >0.5 Ha)
- ❖ aset_peternakan: Kategorikal (Tidak Ada, Unggas, Ruminansia Kecil, Ruminansia Besar)
- ❖ aset_elektronik_inti: Integer (Skor kepemilikan TV, Kulkas, PC/Laptop, AC)

E. Target & Label (Ground Truth)

- ❖ skor_pmt_konvensional: Float (Dihitung manual menggunakan formula regresi statis pemerintah)
- ❖ desil_kesejahteraan_aktual: Integer (1-10, di mana 1-3 adalah kelompok miskin/rentan)
- ❖ is_anomaly: Biner (0 = Normal, 1 = Mis-targeted/Diinjeksi skenario PHK/Bencana)

Namun, mengacu pada prinsip efisiensi komputasi dan menghindari *curse of dimensionality*, MVP RightAid melakukan ekstraksi fitur (*dimensionality reduction* berbasis *domain knowledge*) menjadi 11 Indikator Kesejahteraan Esensial.

Kesebelas fitur ini dipilih karena secara empiris merupakan proksi terkuat dan paling sering menjadi sumber anomali mis-targeting di lapangan:

1. Indikator Dinamis: pengeluaran_per_kapita, status_pekerjaan_kk, dependency_ratio
2. Indikator Statis/Aset: jenis_lantai, daya_listrik_terpasang, kepemilikan_motor, kepemilikan_mobil, status_kepemilikan_rumah
3. Demografi Dasar: usia_kepala_keluarga, lokasi_wilayah (Urban/Rural)
4. Target Pembanding: skor_pmt_konvensional, desil_kesejahteraan_aktual (Label)

B. Arsitektur Model Machine Learning

1. Model Utama MVP (XGBoost + SHAP). Untuk memastikan latensi inferensi yang sangat rendah, keandalan sistem (*robustness*), dan kelancaran demonstrasi *end-to-end* pada tahap MVP, RightAid saat ini ditenagai oleh XGBoost yang dilatih secara khusus pada 11 indikator kesejahteraan esensial di atas. XGBoost dipilih karena efisiensi komputasinya yang superior pada data berdimensi rendah. Kebutuhan mutlak akan *explainability* (keterjelasan model) dalam ranah kebijakan publik dipenuhi secara elegan melalui lapisan *TreeExplainer* dari SHAP. Hal ini memastikan setiap keputusan prediktif model—terutama ketika mendeteksi anomali *mis-targeting*—tetap transparan, dapat diinterpretasi, dan dapat dipertanggungjawabkan oleh analis kebijakan.

● Cara Penggunaan Product

Alur penggunaan RightAid dirancang dari sudut pandang seorang analis kebijakan di Kementerian Sosial atau Dinas Sosial Provinsi yang ingin mengevaluasi potensi mis-targeting di wilayahnya. Seluruh proses dapat diselesaikan tanpa keahlian pemrograman, dalam waktu kurang dari 10 menit.

Langkah 1 — Akses dan Login.

Pengguna mengakses RightAid melalui browser di alamat yang telah didaftarkan. Untuk keperluan demo, tersedia akun tamu dengan kredensial `guest@rightaid.id` / `guest123`. Setelah login, pengguna disambut oleh halaman beranda yang menampilkan ringkasan statistik nasional terkini: jumlah provinsi yang tersedia, rentang data BPS yang digunakan, dan pilihan skenario yang dapat disimulasikan.

Langkah 2 — Pilih Provinsi dan Konfigurasi Skenario.

Di panel kiri halaman utama, pengguna memilih provinsi target dengan mengklik wilayah yang diinginkan pada peta koropleth Indonesia, atau melalui dropdown pencarian provinsi. Setelah provinsi dipilih, sistem otomatis memuat dan menampilkan parameter distribusi BPS untuk provinsi tersebut: proporsi rumah tangga dengan lantai tanah, persentase kepemilikan kendaraan roda empat per kelompok pengeluaran, distribusi akses sanitasi, dan distribusi ukuran rumah tangga. Parameter ini dapat ditinjau pengguna sebelum melanjutkan.

Selanjutnya, pengguna memilih skenario injeksi anomali yang ingin disimulasikan melalui tiga opsi yang disajikan dalam bentuk kartu: (a) Kondisi Normal — dataset murni tanpa anomali yang diinjeksi, berguna sebagai baseline; (b) Skenario PHK Massal — simulasi kenaikan pengangguran 5 persen di sektor manufaktur, di mana sebagian rumah tangga yang sebelumnya berpenghasilan cukup mengalami penurunan ekonomi mendadak; atau (c) Skenario Pasca-Bencana — 10 persen rumah tangga mengalami perubahan kondisi mendadak yang menaikkan kerentanan ekonomi mereka tanpa sempat ter-update dalam sistem bansos. Pengguna juga dapat mengatur slider untuk mengubah persentase rumah tangga yang diinjeksi anomali, antara 5 hingga 30 persen.

Langkah 3 — Generate Dataset Sintetis.

Setelah konfigurasi selesai, pengguna mengklik tombol "Generate Data". Backend FastAPI meneruskan permintaan ke Azure Machine Learning endpoint, yang membangun dataset sintetis berisi 10.000 record rumah tangga yang secara statistik representatif untuk provinsi

yang dipilih. Setiap record memiliki 25 variabel lengkap beserta skor PMT konvensional yang dihitung menggunakan bobot resmi DTKS. Proses ini selesai dalam hitungan detik, dan hasilnya ditampilkan di panel utama sebagai tabel yang dapat difilter dan diurutkan.

Langkah 4 — Jalankan dan Bandingkan Model.

Tombol "Jalankan Analisis" memicu proses inferensi di backend: model XGBoost yang sudah terlatih memberikan prediksi desil dan flag anomali untuk setiap record. Dashboard kemudian menampilkan tiga visualisasi secara bersamaan. Panel pertama adalah confusion matrix interaktif yang membandingkan prediksi PMT konvensional versus ML-PMT terhadap label ground truth. Panel kedua adalah distribusi desil yang diprediksi masing-masing model dalam bentuk histogram berdampingan. Panel ketiga, dan paling actionable, adalah daftar rumah tangga sintetis yang diprediksi berbeda antara kedua model — diurutkan berdasarkan selisih keyakinan prediksi, dari yang paling mungkin mis-targeted hingga yang paling tidak.

Langkah 5 — Eksplorasi SHAP Panel.

Pengguna mengklik salah satu record dari daftar kandidat mis-targeting untuk membuka panel detail di sisi kanan. Panel ini menampilkan SHAP bar chart yang memvisualisasikan kontribusi setiap variabel terhadap prediksi model untuk record tersebut. Sebagai contoh: pada sebuah record yang model prediksi sebagai mis-targeted, chart mungkin menampilkan bahwa "kepemilikan kendaraan roda empat (+2.3)" mendorong prediksi ke arah desil tinggi, sementara "kondisi sanitasi buruk (-1.8)" dan "luas lantai per kapita rendah (-1.4)" mendorong ke arah desil rendah — inkonsistensi inilah yang mengindikasikan potensi mis-targeting. Di bawah SHAP chart, panel juga menampilkan nilai variabel mentah dari record tersebut dalam format tabel yang mudah dibaca.

Langkah 6 — Unduh Laporan dan Generate Policy Brief.

Pengguna dapat mengunduh hasil analisis dalam dua format. Format pertama adalah file CSV berisi seluruh 10.000 record beserta prediksi PMT, prediksi ML-PMT, nilai SHAP per variabel, dan flag anomali — cocok untuk analisis lanjutan menggunakan Excel atau tools statistik lainnya. Format kedua diakses melalui tombol "Buat Rekomendasi", yang mengirimkan ringkasan hasil ke Azure AI Language dan menghasilkan dalam 10-15 detik sebuah policy brief dua halaman dalam Bahasa Indonesia. Policy brief ini mencakup: ringkasan temuan utama dengan angka persentase mis-targeting per skenario, profil demografis kelompok yang paling terdampak, estimasi jumlah rumah tangga yang seharusnya masuk atau keluar dari daftar penerima, serta rekomendasi langkah verifikasi lapangan yang diprioritaskan. Teks ini dapat langsung disalin ke dokumen Word atau presentasi.

Demo credentials: `guest@rightaid..id` / `guest123`

Link prototype: [*https://rightaid.netlify.app/*](https://rightaid.netlify.app/)

GitHub: "<https://github.com/jeremysean/rightaid>"

- **Informasi Pendukung [Opsional]**

Studi Kasus Pengguna

Seorang analis di Bappenas ingin mengetahui dampak potensi PHK massal di sektor manufaktur Jawa Barat terhadap akurasi data DTSEN yang saat ini masih menggunakan survei Regsosek 2022 sebagai fondasi. Dengan RightAid, ia memilih Jawa Barat sebagai provinsi target, mengaktifkan skenario PHK Massal, dan mengklik "Generate Data." Dalam waktu kurang dari tiga menit, ia mendapatkan estimasi bahwa dalam skenario tersebut sekitar 18 persen rumah tangga yang seharusnya naik ke desil 1-3 tidak akan terdeteksi oleh PMT konvensional yang masih menggunakan bobot DTKS lama. Ia kemudian mengunduh policy brief otomatis dan menyajikannya di rapat pimpinan pada hari yang sama — sesuatu yang sebelumnya membutuhkan proses survei dan analisis berbulan-bulan.

Rencana Pengembangan

Transisi ke Arsitektur Deep Learning TabNet. Seiring dengan eskalasi volume data saat RightAid kelak diintegrasikan secara penuh dengan *microdata* Susenas dan SIKS-NG (mencapai jutaan *records*), *core engine* ML akan dimigrasikan dari *tree-based model* ke TabNet. Pendekatan *Deep Learning* mutakhir dari Google yang dirancang khusus untuk data tabular ini akan memberikan dua lompatan teknologi. Pertama, mekanisme *Sequential Attention* bawaan TabNet akan meniadakan dependensi pada *explainer* eksternal seperti SHAP, memberikan interpretasi fitur yang lebih akurat secara *native*. Kedua, RightAid akan memanfaatkan kapabilitas *Self-Supervised Pre-training* TabNet untuk mempelajari representasi wajar (*latent space*) dari kondisi sosio-ekonomi penduduk, sehingga sistem dapat mendeteksi pola anomali *mis-targeting* baru yang belum pernah dilabeli sebelumnya secara *unsupervised*.

Link prototipe

<https://rightaid.netlify.app/>

GitHub Prototype

<https://github.com/jeremysean/rightaid>

Data Pendukung

A. Referensi Kebijakan & Data Pemerintah

- **Kementerian PPN/Bappenas RI.** *Dashboard Registrasi Sosial Ekonomi (Regsosek).* SEPAKAT Demo. Tersedia pada: <https://sepakat-demo.bappenas.go.id/regsosek-dashboard/>
- **Katadata.** (2024). *Bappenas: 46% Penerima Bansos Salah Sasaran karena Kesalahan Pendataan.* Berita Makro Finansial. Tersedia pada: <https://katadata.co.id/finansial/makro/667502d38edee/bappenas-46-penerima-bansos-salah-sasaran-karena-kesalahan-pendataan>

B. Referensi Jurnal Akademik (Machine Learning & Kebijakan Publik)

- **Gonzales Martinez & Cooray.** (2025). *Enhancing Poverty Targeting with Spatial Machine Learning: An application to Indonesia.* arXiv preprint. Tersedia pada: <https://arxiv.org/abs/2503.04300>
- **Chen, T., & Guestrin, C.** (2016). *XGBoost: A Scalable Tree Boosting System.* Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. Tersedia pada: <https://arxiv.org/abs/1603.02754>
- **Lundberg, S. M., & Lee, S. I.** (2017). *A Unified Approach to Interpreting Model Predictions (SHAP).* Advances in Neural Information Processing Systems (NeurIPS). Tersedia pada: <https://arxiv.org/abs/1705.07874>
- **Arik, S. O., & Pfister, T.** (2019). *TabNet: Attentive Interpretable Tabular Learning.* AAAI Conference on Artificial Intelligence. Tersedia pada: <https://arxiv.org/abs/1908.07442>

C. Referensi Repositori Perangkat Lunak

- **DataCebo / SDV-Dev.** *Synthetic Data Vault (SDV): A Python library for creating synthetic data.* Repositori GitHub. Tersedia pada: <https://github.com/sdv-dev/sdv>