

RightAid

ML-PMT Refresher Platform

Dataset, Notebook & Feature Engineering Documentation

Dicoding x Microsoft Elevate Datathon 2025 | Ekonomi Digital & Inklusi Keuangan

Jeremy Sean Sitranata | Stevan Pohan | Takeshi Henderson Herman

1. Overview

RightAid adalah platform analitik berbasis web yang membantu analis kebijakan mendeteksi ketidaktepatan sasaran (mis-targeting) pada program perlindungan sosial Indonesia. Platform ini menggunakan pendekatan ML-PMT Refresher: membandingkan prediksi model Machine Learning terhadap sistem Proxy Means Testing (PMT) konvensional untuk mengidentifikasi rumah tangga yang salah diklasifikasikan.

Dokumen ini menjelaskan secara rinci:

- Sumber dan struktur dataset sintetis yang digunakan
 - Variabel mentah (25 variabel) dan asal-usulnya
 - Proses EDA berbasis hipotesis (framework PPDAC)
 - Fitur yang direkayasa (16 fitur) beserta justifikasi ilmiahnya
 - Feature set final untuk modeling (Setup A)
-

2. Dataset

2.1 Pendekatan Data Sintetis

RightAid menggunakan data sintetis karena microdata individu penerima bantuan sosial (DTKS/SIKS-NG) dilindungi regulasi dan tidak tersedia secara publik. Pendekatan ini sesuai dengan metodologi yang digunakan World Bank dan UNDP untuk analisis kebijakan sosial.

Data sintetis dikalibrasi dari dua sumber publik yang terverifikasi:

Sumber	Data yang Diambil	Coverage	Akses
DHS Indonesia 2017 (IDHS-VII)	Distribusi kondisi perumahan (lantai, dinding, atap), kepemilikan aset, urban/rural split, household size	34 provinsi asli	IPUMS DHS (akademik)
Susenas 2025 BPS (PDF Tabel II & V)	Mean pengeluaran per kapita per provinsi (urban/rural terpisah), pangsa pengeluaran pangan (food share)	38 provinsi	Publik, download BPS

2.2 Spesifikasi Dataset

Parameter	Nilai
Total records	1.140.000 baris
Provinsi	38 provinsi (34 asli + 4 Papua pemekaran)
Skenario	3: normal, phk, bencana
Records per provinsi per skenario	10.000
File format	Parquet
Ukuran file	~30 MB
Random seed	42 (reproducible)
Kalibrasi pengeluaran	Error < 0.6% vs target Susenas 2025
Kalibrasi urban share	Error < 2pp vs DHS 2017

2.3 Tiga Skenario

Skenario	Deskripsi	Anomaly Rate	Logika Injeksi
normal	Baseline tanpa injeksi anomali	0%	Data murni sesuai distribusi kalibrasi
phk	Simulasi PHK massal sektor manufaktur	5% (500 dari 10.000)	Target: pekerja formal sektor manufaktur. Pengeluaran turun 40-70%, status pekerjaan -> tidak bekerja. Aset fisik (motor, mobil, lantai) TIDAK

Skenario	Deskripsi	Anomaly Rate	Logika Injeksi
			berubah. Ini menciptakan asset-income mismatch yang menjadi blind spot PMT.
bencana	Simulasi pasca bencana alam	10% (1.000 dari 10.000)	Target: rumah tangga acak. Kondisi fisik memburuk (lantai, air, toilet turun drastis). Pengeluaran turun 30-50%. PMT score dihitung SEBELUM injeksi (simulasi data DTKS yang belum ter-update).

3. Variabel Mentah (25 Variabel)

Dataset mengandung 25 variabel kelayakan yang diadaptasi dari kuesioner Regsosek dan DTKS, identik dengan standar data pemerintah untuk memastikan plug-and-play compatibility.

3.1 Variabel Identitas & Metadata

Variabel	Tipe	Deskripsi	Sumber
record_id	str	ID unik 8 karakter per record (UUID)	Generated
province	str	Nama provinsi	Config
urban_rural	int	1 = urban, 2 = rural	DHS 2017 urban_pct_dhs
scenario	str	normal / phk / bencana	Generator
anomaly_pct	float	Persentase injeksi anomali pada batch ini	Generator
dataset_id	str	ID batch generate (12 karakter)	Generator

3.2 Variabel Demografi (4 variabel)

Variabel	Tipe	Range/Kategori	Deskripsi	Sumber Distribusi
jml_anggota_keluarga	int	1 - 12	Jumlah anggota keluarga. Di-generate dari distribusi Poisson($\lambda = \text{hh_size_mean} - 1$) + 1, truncated di [1,12].	DHS 2017 hh_size_mean per provinsi
usia_kepala_keluarga	int	18 - 90	Usia kepala keluarga. Di-generate dari Normal(mean=45, std=12), truncated di [18,90].	Asumsi nasional
gender_kepala_keluarga	int	1=Laki-laki, 2=Perempuan	Gender kepala keluarga. 89% laki-laki sesuai rata-rata nasional Susenas.	Susenas nasional
dependency_ratio	float	0.0 - 3.0	Rasio anggota tidak produktif vs produktif. Di-generate dari Normal(0.8, 0.4), truncated di	Asumsi nasional

Variabel	Tipe	Range/Kategori	Deskripsi	Sumber Distribusi
			[0,3].	

3.3 Variabel Kondisi Fisik Bangunan (5 variabel)

Ini adalah variabel utama PMT konvensional (bobot terbesar dalam Permensos No. 5 Tahun 2019).

Variabel	Tipe	Kode Utama	Deskripsi	Sumber Distribusi
status_kepemilikan_rumah	int	1=Milik sendiri, 2=Kontrak/Sewa, 3=Bebas Sewa, 4=Dinas	Status kepemilikan rumah. 80% milik sendiri sesuai rata-rata nasional.	Asumsi nasional
luas_lantai_per_kapita	float	2 - 80 m2/orang	Luas lantai per kapita dalam m2. LogNormal: urban mean exp(2.3), rural exp(2.1).	Asumsi berbasis Susenas
jenis_lantai	int	11=Tanah, 21=Kayu, 32=Semen, 33=Keramik, 35=Granit (kode DHS)	Jenis material lantai. Kode DHS IDHR71 variable hv213. Merupakan proxy kemiskinan terkuat di PMT lama.	DHS 2017 floor_material_dist per provinsi
jenis_dinding	int	12=Bambu, 23=Plywood, 31=Bata tanpa plester, 34=Tembok plester (kode DHS)	Jenis material dinding. Kode DHS IDHR71 variable hv214.	DHS 2017 wall_material_dist per provinsi
jenis_atap	int	12=Ijuk, 31=Seng, 32=Asbes, 33=Genteng (kode DHS)	Jenis material atap. Distribusi nasional dari DHS: 49.1% seng, 36.2% genteng.	DHS 2017 distribusi nasional

3.4 Variabel Utilitas & Sanitasi (4 variabel)

Variabel	Tipe	Kode Utama	Deskripsi	Sumber Distribusi
sumber_air_minum	int	11=PAM, 21=Sumur terlindung, 31=Sumur tak terlindung, 41=Permukaan (kode DHS)	Sumber air minum. Kode DHS hv201. Proxy aksesibilitas layanan dasar.	DHS 2017 water_source_dist per provinsi
fasilitas_bab	int	12=Flush+septic, 16=Flush+pit, 21=Cubluk+slab, 51=Terbuka (kode DHS)	Fasilitas BAB. Kode DHS hv205. Nasional: 70.1% flush+septic, 10% terbuka.	DHS 2017 toilet_dist per provinsi
daya_listrik_terpasang	int	0=Tidak ada, 450, 900, 1300, 2200 (VA)	Daya listrik terpasang. Dikondisikan pada electricity=1. Distribusi:	Asumsi berbasis Susenas

Variabel	Tipe	Kode Utama	Deskripsi	Sumber Distribusi
			12% 450VA, 28% 900VA, 38% 1300VA, 22% 2200VA+.	
bahan_bakar_memasak	int	1=Listrik, 2=LPG, 5=Minyak tanah, 8=Kayu bakar (kode DHS)	Bahan bakar memasak. Kode DHS hv226. Nasional: 65.3% LPG, 24.5% kayu bakar.	DHS 2017 cooking_fuel_dist per provinsi

3.5 Variabel Ekonomi & Aset (9 variabel)

Variabel	Tipe	Range/Kategori	Deskripsi	Sumber Distribusi
pendidikan_kepala_keluarga	int	0=Tidak sekolah, 1=SD, 2=SMP, 3=SMA, 4=PT	Tingkat pendidikan kepala keluarga. Distribusi dari DHS PR recode education_level.	DHS 2017 education_level nasional
status_pekerjaan_kk	int	0=Tidak bekerja, 1=Informal, 2=Formal, 3=Wirausaha	Status pekerjaan kepala keluarga. Urban: 35% formal. Rural: 65% informal.	Asumsi berbasis Sakernas
sektor_pekerjaan_kk	int	1=Pertanian, 2=Jasa, 3=Manufaktur, 4=Konstruksi	Sektor pekerjaan. Rural: 55% pertanian. Urban: 55% jasa, 28% manufaktur.	Asumsi berbasis Sakernas
pengeluaran_per_kapita	int	200.000 - 15.000.000 (Rp/bulan)	FITUR PALING KRITIS. Pengeluaran per kapita per bulan. Di-generate dari LogNormal yang dikalibrasi terhadap Susenas 2025. Error < 0.6% vs target. TIDAK dipakai sebagai model feature (Setup A) karena tidak tersedia di DTKS real.	Susenas 2025 BPS Tabel II (per provinsi, urban/rural)
kepemilikan_motor	int	0=Tidak, 1=Ya	Kepemilikan sepeda motor. Binary. Error < 1pp vs DHS 2017.	DHS 2017 pct_motorcycle per provinsi
kepemilikan_mobil	int	0=Tidak, 1=Ya	Kepemilikan mobil/truck. Binary.	DHS 2017 pct_car per provinsi
aset_lahan_pertanian	int	0=Tidak ada, 1=<0.5 ha, 2=>0.5 ha	Kepemilikan lahan pertanian. Hanya di-generate untuk sektor pertanian.	Asumsi
aset_peternakan	int	0=Tidak ada, 1=Unggas, 2=Ruminansia kecil, 3=Ruminansia besar	Kepemilikan ternak. Hanya di-generate untuk sektor pertanian.	Asumsi

Variabel	Tipe	Range/Kategori	Deskripsi	Sumber Distribusi
aset_elektronik_inti	int	0 - 4	Skor kepemilikan elektronik: TV + kulkas + PC/laptop + AC. Dikondisikan pada wealth_index dari DHS.	DHS 2017 wealth_index_dist per provinsi

3.6 Variabel Label & Target (3 variabel)

Variabel	Tipe	Range	Deskripsi	Catatan
skor_pmt_konvensional	float	0 - 100	Skor PMT yang dihitung menggunakan bobot statis Permensos No. 5 Tahun 2019. Formula weighted sum dari lantai (22%), air (15%), toilet (15%), listrik (10%), bahan bakar (8%), motor (8%), mobil (10%), TV (6%), kulkas (6%). Dihitung SEBELUM injeksi anomali untuk mensimulasikan data DTKS yang stale.	Dipakai sebagai COMPARATOR, bukan model feature
desil_kesejahteraan_aktual	int	1 - 10	Ground truth desil kesejahteraan. Desil 1 = termiskin. Di-compute dari pengeluaran_per_kapita via safe_qcut_desil(). Ini adalah TARGET untuk task klasifikasi desil.	Target utama (Task 1)
is_anomaly	int	0 atau 1	Flag mis-targeting. 1 = rumah tangga yang diinjeksi sebagai anomali (PHK atau bencana). Ini adalah TARGET untuk task deteksi anomali.	Target utama (Task 2)

4. Exploratory Data Analysis (EDA)

EDA dilakukan menggunakan framework PPDAC (Problem-Plan-Data-Analysis-Conclusion) yang dikombinasikan dengan pendekatan Hypothesis-Driven. Setiap analisis dimulai dari hipotesis yang didefinisikan a priori, diuji secara statistik, dan kesimpulannya langsung menentukan keputusan feature engineering.

4.1 Framework: PPDAC x Hypothesis-Driven

Phase PPDAC	Isi	Output
Problem	Definisi masalah: PMT statis menyebabkan exclusion error 46%	3 Research Questions dari proposal
Plan	8 hipotesis null didefinisikan a priori sebelum melihat data, lengkap dengan statistical test yang akan digunakan	Hypothesis plan document

Phase PPDAC	Isi	Output
Data	Load, validasi kualitas, karakterisasi distribusi dasar	Data quality report, null checks, range checks
Analysis	Test 8 hipotesis secara berurutan dengan Mann-Whitney U, Chi-square, Fisher z-test, KS test, Logistic Regression	p-values, confidence intervals, visualisasi
Conclusion	Sintesis: hipotesis mana yang confirmed, dan apa implikasinya untuk feature engineering	Feature engineering decisions table

4.2 Hasil Uji Hipotesis

Hipotesis	Test Statistik	p-value	Hasil	FE Decision
H1a: PMT Static Bias (FN vs TN PMT score)	Mann-Whitney U	0.3230	NOT CONFIRMED	asset_income_mismatch tetap ditambah karena profile FN menunjukkan motor 86.3% vs nasional 74.4%
H1b: Shock Sensitivity (exclusion error per skenario)	Chi-square	0.8228	NOT CONFIRMED	Karena PMT score dihitung identik — justru membuktikan PMT tidak sensitif terhadap shock
H1c: Dynamic > Static features (Fisher z-test korelasi)	Fisher z-test	$p < 0.0001$	CONFIRMED	log_pengeluaran sebagai primary predictor ($r=0.79$ vs $r<0.002$ untuk static features)
H2a: PHK Asset-Income Mismatch	Mann-Whitney U	0.0348	CONFIRMED	high_asset_low_income_flag: (aset_score ≥ 3) & (pengeluaran < Q25)
H2b: Bencana Floor Deterioration	Mann-Whitney U	$p < 0.0001$	CONFIRMED	floor_quality sebagai encoded ordinal feature
H2c: PHK vs Bencana Distinct Signatures	KS test	$p < 0.0001$	CONFIRMED	Dua tipe anomali punya distribusi berbeda secara signifikan
H3a: Pengeluaran vs PMT Dominance	Fisher z-test	$p < 0.0001$	CONFIRMED	log_pengeluaran $r=0.79$ vs PMT $r=0.0006$ -- superiority confirmed
H3b: Graduation Signal (mobil x high_income)	Logistic Regression OR	OR=0.969	NOT CONFIRMED	graduation_signal di-drop; high_income sendiri sudah OR=2.947

Catatan penting dari H1a dan H1b: kedua hipotesis tidak terkonfirmasi secara statistik, namun hasil ini justru memperkuat argumen utama RightAid. PMT score yang identik antara kelompok FN dan TN menunjukkan bahwa PMT memang tidak sensitif terhadap perbedaan income aktual -- ini adalah bukti langsung mengapa sistem ini gagal.

5. Feature Engineering

Semua fitur yang direkayasa memiliki justifikasi yang berasal dari hasil hipotesis EDA di atas. Tidak ada fitur yang ditambahkan secara arbitrary.

5.1 Fitur yang Di-drop dan Alasannya

Fitur yang Di-drop	Alasan
pengeluaran_per_kapita & log_pengeluaran	Circular dengan target: desil_aktual = f(pengeluaran). Juga tidak tersedia di DTKS real -- model harus belajar dari proxy saja (Setup A = deployment-realistic scenario).
skor_pmt_konvensional & desil_pmt_konvensional	Model shortcut prevention: jika PMT score dijadikan fitur, model akan belajar dari PMT bukan dari raw features. Disimpan sebagai comparator untuk evaluasi.
graduation_signal	H3b NOT CONFIRMED: OR=0.969, tidak ada nilai marginal dari interaksi mobil x high_income.
pmt_overestimate_flag	Derived dari desil_pmt -- drop ikut dengan PMT features.

5.2 Fitur Final: Setup A (16 Fitur)

Setup A mensimulasikan constraint deployment nyata: model hanya menggunakan variabel yang tersedia di survei DTKS/Regsosek, tanpa akses ke data income langsung.

#	Nama Fitur	Tip e	Ran ge	Asal Variabel	Transformasi	Justifikasi (Hipotesis)
1	employment_vulnerability	int	0-3	status_pekerjaan_kk	Ordinal remap: formal=0, wirausaha=1, informal=2, tidak bekerja=3 (higher=more vulnerable)	H2a confirmed: employment status sebagai dynamic vulnerability signal
2	dependency_ratio	float	0.0-3.0	dependency_ratio	Langsung dari generator, StandardScaler di modeling	Dynamic feature, tidak tersedia di PMT konvensional
3	floor_quality	int	0-5	jenis_lantai	OrdinalEncoder: 11(tanah)=0, 12(bambu)=1, 21(kayu)=2, 32(semen)=3, 33(keramik)=4, 35(granit)=5	H2b confirmed: floor deterioration signature pada bencana anomaly
4	daya_listrik_ord	int	0-4	daya_listrik_terpasang	OrdinalEncoder: 0VA=0, 450VA=1, 900VA=2, 1300VA=3, 2200VA+=4	Proxy kesejahteraan yang lebih sensitif dari binary electricity flag
5	status_rumah_ord	int	0-2	status_kepemilik	OrdinalEncoder:	Proxy stabilitas ekonomi

#	Nama Fitur	Tip e	Ran ge	Asal Variabel	Transformasi	Justifikasi (Hipotesis)
				an_rumah	kontrak/bebas/dinas=0, milik sendiri=1 (simplified)	jangka panjang
6	kepemilikan_motor	int	0-1	kepemilikan_motor	Binary, langsung dari generator	Aset fisik utama PMT; dikalibrasi dari DHS 2017 per provinsi
7	kepemilikan_mobil	int	0-1	kepemilikan_mobil	Binary, langsung dari generator	Aset fisik PMT; key asset dalam asset-income mismatch signal (H1a, H2a)
8	aset_score	int	0-4	kepemilikan_motor + kepemilikan_mobil + has_tv + has_fridge	Sum dari 4 binary asset flags	Composite asset proxy; menangkap overall wealth lebih baik dari asset tunggal
9	aset_elektronik_inti	int	0-4	has_tv + has_fridge + has_pc + has_ac	Sum dari 4 binary electronic asset flags; PC/AC dikondisikan pada wealth_index DHS	Proxy modern consumption level
10	usia_kepala_keluarga	int	18-90	usia_kepala_keluarga	Langsung dari generator, StandardScaler di modeling	Demographic control; berkorelasi dengan lifecycle wealth accumulation
11	is_urban_bin	int	0-1	urban_rural	Binary recode: urban_rural==1 -> 1, urban_rural==2 -> 0	Urban/rural sebagai spatial context; penting karena distribusi kemiskinan berbeda signifikan
12	asset_income_mismatch	int	0-1	aset_score, pengeluaran_per_kapita	Binary: (aset_score >= 3) AND (pengeluaran < Q25 nasional). Q25 dihitung dari full dataset.	H1a: profile FN group menunjukkan high asset + low income. Menangkap mis-targeting signature.
13	high_asset_low_income_flag	int	0-1	aset_score, pengeluaran_per_kapita	Binary: sama dengan asset_income_mismatch (deliberate redundancy untuk feature ablation study)	H2a CONFIRMED: PHK anomaly punya higher asset score meski income collapse (p=0.0348)
14	has_tv	int	0-1	has_tv	Binary, langsung dari generator	Dikalibrasi dari DHS 2017 pct_tv per provinsi (85.2% nasional)
15	has_fridge	int	0-1	has_fridge	Binary, langsung dari generator	Dikalibrasi dari DHS 2017 pct_fridge per provinsi (57.3% nasional)
16	has_mobile	int	0-1	has_mobile	Binary, langsung dari generator	Dikalibrasi dari DHS 2017 pct_mobile per provinsi

#	Nama Fitur	Tip e	Ran ge	Asal Variabel	Transformasi	Justifikasi (Hipotesis)
						(89.6% nasional)

5.3 Comparators (tidak dipakai sebagai model feature)

Variabel	Fungsi
skor_pmt_konvensional	Dibandingkan dengan prediksi ML untuk menghitung PMT error rate, exclusion error, dan mis-targeting gap di evaluation dashboard
desil_pmt_konvensional	Dipakai untuk confusion matrix PMT vs ML vs ground truth di frontend RightAid
pengeluaran_per_kapita	Dipakai untuk konstruksi target (desil_aktual) dan untuk validasi kalibrasi synthetic engine

6. Alur Notebook

#	Notebook	Input	Output	Status
1	DHS EDA Explorer	IDHR71FL.DTA, IDPR71FL.DTA (DHS 2017)	province_config_dhs2017.json	DONE
2	Dataset Merger	province_config_dhs2017.json + Susenas 2025 (hardcoded)	province_master_config.json	DONE
3	Synthetic Data Generator v2	province_master_config.json	synthetic_all_provinces.parquet (1.14M rows, 30MB)	DONE
4	EDA + Feature Engineering	synthetic_all_provinces.parquet	rightaid_processed.parquet (1.14M rows, 48 cols, 42MB) + eda_metadata.json	DONE
5	XGBoost Modeling	rightaid_processed.parquet + eda_metadata.json	xgboost_desil_v1.pkl, xgboost_anomaly_v1.pkl, evaluation_report.json	NEXT

7. Feature Set Final (Setup A) -- Cell 16 EDA Notebook

Cell ini ditambahkan di akhir EDA notebook (setelah Cell 15) untuk merevisi feature set sebelum masuk ke modeling notebook. Fitur yang di-drop berdasarkan analisis circular target construction dan PMT shortcut prevention.

Code: Cell 16 -- Setup A Feature Set

Paste sebagai cell tambahan di akhir EDA notebook:

```
#
=====
# CELL 16 -- Setup A Feature Set (revised post-analysis)
# Drop: log_pengeluaran, skor_pmt_konvensional, desil_pmt_konvensional,
#       graduation_signal (H3b not confirmed), pmt_overestimate_flag
# Reason: circular target construction + PMT shortcut prevention
#
=====

MODEL_FEATURES_A = [
    "employment_vulnerability",
    "dependency_ratio",
    "floor_quality",
    "daya_listrik_ord",
    "status_rumah_ord",
    "kepemilikan_motor",
    "kepemilikan_mobil",
    "aset_score",
    "aset_elektronik_inti",
    "usia_kepala_keluarga",
    "is_urban_bin",
    "asset_income_mismatch",
    "high_asset_low_income_flag",
    "has_tv",
    "has_fridge",
    "has_mobile",
]

# Update metadata
metadata["model_features"] = MODEL_FEATURES_A
metadata["setup"]          = "A"
metadata["setup_rationale"] = (
    "Drop pengeluaran (circular with target), PMT score (shortcut
prevention). "
    "Model must learn from proxy variables only -- mirrors real DTKS
deployment."
)

with open(OUTPUT_DIR / "eda_metadata.json", "w", encoding="utf-8") as f:
    json.dump(metadata, f, indent=2, ensure_ascii=False)
```

```
print(f'Setup A features ({len(MODEL_FEATURES_A)}): {MODEL_FEATURES_A}')  
logger.info('setup_a_features_saved n=%d', len(MODEL_FEATURES_A))
```

8. Referensi

- Gonzales Martinez & Cooray (2025). Enhancing Poverty Targeting with Spatial Machine Learning. arXiv:2503.04300
- Chen, T. & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. arXiv:1603.02754
- Lundberg, S.M. & Lee, S.I. (2017). A Unified Approach to Interpreting Model Predictions (SHAP). NeurIPS. arXiv:1705.07874
- Permensos No. 5 Tahun 2019 -- Bobot PMT konvensional DTKS
- BPS. Susenas 2025 -- Pengeluaran untuk Konsumsi Penduduk Indonesia (Tabel II & V)
- DHS Program (2017). Indonesia Demographic and Health Survey 2017 (IDHS-VII). Rockville, MD: ICF
- Katadata (2024). Bappenas: 46% Penerima Bansos Salah Sasaran karena Kesalahan Pendataan